

Báo Cáo Tóm Tắt Dự Án: Chatbot Hỗ Trợ Đặt Món Ăn Online

1. Giới Thiệu và Bối Cảnh Dự Án

Trong bối cảnh ngành dịch vụ đặt món ăn online ngày càng cạnh tranh, việc nâng cao trải nghiệm khách hàng là yếu tố sống còn. Khách hàng thường có nhiều thắc mắc về thực đơn, từ thành phần món ăn, gợi ý món đặc sắc, cho đến các lựa chọn phù hợp với chế độ ăn kiêng. Việc giải đáp thủ công các câu hỏi này tốn nhiều thời gian và không đảm bảo tính nhất quán.

Chatbot Hỗ Trợ Đặt Món Ăn Online ra đời nhằm giải quyết thách thức này bằng cách xây dựng một trợ lý ảo thông minh. Mục tiêu cốt lõi là tạo ra một chatbot có khả năng hiểu và trả lời các câu hỏi của khách hàng về thực đơn nhà hàng một cách tự nhiên, chính xác và tức thì, hoàn toàn bằng tiếng Việt.

1. Mục Tiêu và Các Cột Mốc Đã Hoàn Thành

Dự án đã hoàn thành giai đoạn phát triển sản phẩm khả thi tối thiểu và đạt được tất cả các mục tiêu đề ra:

- Trả lời câu hỏi về thực đơn:** Chatbot có khả năng cung cấp thông tin chi tiết về các món ăn dựa trên dữ liệu được cung cấp.
- Tích hợp RAG Pipeline:** Xây dựng thành công kiến trúc Retrieval-Augmented Generation(RAG), cho phép chatbot truy xuất thông tin chính xác từ một cơ sở tri thức (ở đây là thực đơn) trước khi tạo câu trả lời, giúp hạn chế tối đa việc bịa thông tin(Hallucination).
- Hỗ trợ tiếng Việt hoàn chỉnh:** Từ giao diện đến khả năng xử lý ngôn ngữ tự nhiên, hệ thống được tối ưu hoàn toàn cho người dùng tiếng Việt.
- Ghi nhớ cuộc trò chuyện:** Chatbot có khả năng lưu lại ngữ cảnh của cuộc hội thoại, giúp các tương tác trở nên liền mạch và tự nhiên hơn.
- Đóng gói bằng Docker:** Toàn bộ ứng dụng đã được container hóa bằng Docker, tích hợp sẵn hỗ trợ CUDA cho GPU, giúp việc triển khai trên mọi môi trường trở nên dễ dàng, nhanh chóng và nhất quán.

3. Phân Tích Kiến Trúc Hệ Thống

3.1. Các Thành Phần Cốt Lõi (Core Components)

- LangChain (Framework):** Đóng vai trò là bộ não điều phối, kết nối tất cả các thành phần khác lại với nhau. LangChain chịu trách nhiệm quản lý luồng dữ liệu, từ việc tiếp nhận câu hỏi của người dùng đến việc gửi câu trả lời cuối cùng.
- Qwen2.5-3B-Instruct (LLM):** Là mô hình ngôn ngữ lớn thực hiện nhiệm vụ tạo sinh văn bản. Mô hình này được lựa chọn vì có hiệu năng tạm ổn, kích thước nhỏ (3 tỷ tham số) phù hợp để triển khai khi tài nguyên tính toán hạn chế.
- ChromaDB (Vector Database):** Đóng vai trò là thư viện tri thức. Toàn bộ dữ liệu về thực đơn được chuyển đổi thành các vector số học và lưu trữ tại đây. ChromaDB cho phép tìm kiếm ngữ nghĩa cực kỳ nhanh chóng với phương pháp được sử dụng trong dự án là Cosine Similarity.
- Hugging Face Embeddings (Sentence Transformers):** Là công cụ mã hóa ngôn ngữ. Nó chuyển đổi cả câu hỏi của người dùng và dữ liệu trong thực đơn thành các vector embedding. Quá trình này giúp máy tính có thể hiểu và so sánh ý nghĩa của ngôn ngữ tự nhiên.

3.2. Luồng Xử Lý Dữ Liệu (Data Flow)

Khi người dùng gửi một câu hỏi, hệ thống sẽ xử lý theo quy trình 5 bước của RAG:

- Tiếp nhận (User Query):** Người dùng nhập câu hỏi.
- Vector hóa và Tìm kiếm (Vector Search):** Câu hỏi được mô hình embedding chuyển thành một vector. Hệ thống sử dụng vector này để tìm kiếm trong ChromaDB những phần thông tin có nội dung ngữ nghĩa liên quan nhất.
- Truy xuất Ngữ cảnh (Context Retrieval):** Các thông tin có độ tương đồng cao nhất so với query trong ChromaDB được lấy ra, cùng với đó là lịch sử trò chuyện. Đây chính là ngữ cảnh (context).
- Tạo sinh Câu trả lời (LLM Generation):** Ngữ cảnh này được gửi kèm với câu hỏi ban đầu làm đầu vào cho một prompt được thiết kế với những chỉ định riêng cho cách hoạt động của mô hình. Mô hình sẽ dựa vào prompt được cung cấp để tạo ra một câu trả lời chính xác và phù hợp.
- Phản hồi (Response):** Câu trả lời cuối cùng được gửi lại cho người dùng.

4. Kết Quả và Hiệu Suất

4.1 Tính năng nổi bật:

- Tìm kiếm ngữ nghĩa:** Cho phép người dùng tìm kiếm món ăn dựa trên mô tả, tính chất thay vì chỉ tìm theo từ khóa chính xác.
- Phản hồi dựa trên ngữ cảnh:** Đảm bảo mọi câu trả lời đều bám sát thông tin có trong thực đơn, tăng độ tin cậy và tránh các câu trả lời sai lệch.

4.2 Hiệu suất:

- **Thời gian phản hồi và độ chính xác:** Phụ thuộc hoàn toàn vào sự tương thích giữa phần cứng và mô hình LLM: Với tài nguyên VRAM là 4gb, sử dụng model 0.5B tham số sẽ có thời gian phản hồi nhanh(1-2s), tuy nhiên mô hình lại kém chính xác, thường đưa ra thông tin không đúng so với vector database. Nếu sử dụng model 3B tham số thì sẽ chính xác hơn nhiều, tuy nhiên thời gian phản hồi khá là lâu. Cần phải tính toán kĩ trong việc lựa chọn mô hình để cân bằng giữa thời gian phản hồi và độ chính xác trong điều kiện tài nguyên tính toán hạn chế.
- **Khả năng mở rộng:** Kiến trúc cho phép dễ dàng thay thế mô hình 3B bằng các mô hình lớn hơn (7B, 14B) để tăng cường khả năng suy luận mà không cần thay đổi toàn bộ hệ thống(nếu tài nguyên tính toán cho phép).

5. Thách Thức và Giải Pháp Thực Tiễn

- Kích thước model lớn đòi hỏi bộ nhớ VRAM cao, gây khó khăn cho việc triển khai. Có thể áp dụng kỹ thuật Quantization, giảm độ chính xác của các con số trong model (từ 16-bit xuống 4-bit/8-bit). Giải pháp này giúp giảm đáng kể dung lượng VRAM cần thiết mà chỉ ảnh hưởng không đáng kể đến chất lượng đầu ra.
- Có thể tăng độ chính xác khi truy vấn vector database bằng MultiQueryRetriever, cách hoạt động là dùng mô hình LLM để sinh các câu query khác tương tự như query gốc, từ đó dùng nhiều query để truy xuất thông tin, tuy nhiên, thời gian phản hồi sẽ tăng lên đáng kể.

6. Kết Luận và Hướng Phát Triển

Dự án đã thành công trong việc xây dựng một nguyên mẫu chatbot mạnh mẽ cho nhà hàng. Sản phẩm không chỉ giải quyết được bài toán về nghiệp vụ mà còn sở hữu một nền tảng kỹ thuật vững chắc, có khả năng mở rộng và dễ dàng triển khai nhờ kiến trúc RAG và công nghệ Docker.

Hướng phát triển trong tương lai:

- **Tối ưu hóa Prompt Engineering:** Tinh chỉnh các câu lệnh chỉ dẫn cho LLM để tạo ra các câu trả lời tự nhiên, đa dạng và phù hợp hơn.
- **Mở rộng bộ câu hỏi:** Huấn luyện hệ thống để xử lý các câu hỏi phức tạp hơn liên quan đến việc kết hợp món ăn, gợi ý theo sự kiện, v.v.
- **Tích hợp giao diện giọng nói (Voice Interface):** Cho phép khách hàng tương tác với chatbot bằng giọng nói.
- **Nâng cấp mô hình ngôn ngữ:** Chuyển sang các model lớn hơn như 7B hoặc 14B để tăng cường khả năng suy luận và hiểu các câu hỏi phức tạp.

7. Demo

Build image:

```
C:\Users\duong\OneDrive\Máy tính\LLM>docker build --no-cache -t chatbot:latest .
[+] Building 1281.6s (12/12) FINISHED                                docker:desktop-linux
=> [internal] load build definition from Dockerfile                  0.0s
=> => transferring dockerfile: 410B                                  0.0s
=> [internal] load metadata for docker.io/nvidia/cuda:12.1.1-cudnn8-runtime-ubuntu22.04 3.4s
=> [internal] load .dockerignore                                     0.0s
=> => transferring context: 2B                                         0.0s
=> [internal] load build context                                     0.0s
=> => transferring context: 9.66kB                                     0.0s
=> CACHED [1/7] FROM docker.io/nvidia/cuda:12.1.1-cudnn8-runtime-ubuntu22.04@sha256:f4d8e1264366940438f0353da6f2 0.0s
=> => resolve docker.io/nvidia/cuda:12.1.1-cudnn8-runtime-ubuntu22.04@sha256:f4d8e1264366940438f0353da6f289c7bef 0.0s
=> [2/7] RUN apt-get update && apt-get install -y python3-pip && rm -rf /var/lib/apt/lists/* 203.6s
=> [3/7] RUN ln -sf /usr/bin/python3 /usr/bin/python               0.5s
=> [4/7] WORKDIR /app                                              0.0s
=> [5/7] COPY requirements.txt .                                    0.0s
=> [6/7] RUN pip install --no-cache-dir -r requirements.txt        592.8s
=> [7/7] COPY . .                                                  1.8s
=> exporting to image                                              478.9s
=> => exporting layers                                              387.9s
=> => exporting manifest sha256:1bb2055e44f89f2e8f4dd4354857f63d508109a0359fd7c272cc8418b26ce64d 0.0s
=> => exporting config sha256:8080ca0fd5fdc2ccaf0727b36110334efc11a173b37e1119f9d684e3058c527a 0.0s
=> => exporting attestation manifest sha256:00afc5d991244f3babf0242935a6fe618fca8a19cdc60bace4fdc5275d7ab94d 0.0s
=> => exporting manifest list sha256:21b3b5177a84c4d0e4194c0cc8b6c6a001a15204363f1a672a1298d5528d687c 0.0s
=> => naming to docker.io/library/chatbot:latest                   0.0s
=> => unpacking to docker.io/library/chatbot:latest                90.7s

View build details: docker-desktop://dashboard/build/desktop-linux/desktop-linux/qswt9tmb0un3rr574zcr2lcb
C:\Users\duong\OneDrive\Máy tính\LLM>
```

Run container:

```
c:\Users\duong\OneDrive\Máy tính>docker run --gpus all -it chatbot

=====
== CUDA ==
=====

CUDA Version 12.1.1

Container image Copyright (c) 2016-2023, NVIDIA CORPORATION & AFFILIATES. All rights reserved.

This container image and its contents are governed by the NVIDIA Deep Learning Container License.
By pulling and using the container, you accept the terms and conditions of this license:
https://developer.nvidia.com/ngc/nvidia-deep-learning-container-license

A copy of this license is made available in this container at /NGC-DL-CONTAINER-LICENSE for your convenience.

modules.json: 100%|██████████████████████████████████████████████████████████████████████████████| 229/229 [00:00<00:00, 1.7MB/s]
config_sentence_transformers.json: 100%|██████████████████████████████████████████████████████████████████████████████| 122/122 [00:00<00:00, 766kB/s]
README.md: 5.12kB [00:00, 1.36MB/s]
sentence_bert_config.json: 100%|██████████████████████████████████████████████████████████████████████████████| 53.0/53.0 [00:00<00:00, 18.1kB/s]
/usr/local/lib/python3.10/dist-packages/huggingface_hub/file_download.py:945: FutureWarning: `resume_download` is deprecated and will be removed in version
1.0.0. Downloads always resume when possible. If you want to force a new download, use `force_download=True`.
    warnings.warn(
config.json: 100%|██████████████████████████████████████████████████████████████████████████████| 727/727 [00:00<00:00, 3.45MB/s]
model.safetensors: 100%|██████████████████████████████████████████████████████████████████████████████| 1.11G/1.11G [00:47<00:00, 23.6MB/s]
tokenizer_config.json: 100%|██████████████████████████████████████████████████████████████████████████████| 402/402 [00:00<00:00, 455kB/s]
sentencepiece.bpe.model: 100%|██████████████████████████████████████████████████████████████████████████████| 5.07M/5.07M [00:00<00:00, 6.78MB/s]
tokenizer.json: 9.08MB [00:00, 19.9MB/s]
special_tokens_map.json: 100%|██████████████████████████████████████████████████████████████████████████████| 239/239 [00:00<00:00, 1.69MB/s]
config.json: 100%|██████████████████████████████████████████████████████████████████████████████| 190/190 [00:00<00:00, 211kB/s]
Failed to send telemetry event ClientStartEvent: capture() takes 1 positional argument but 3 were given
Failed to send telemetry event ClientCreateCollectionEvent: capture() takes 1 positional argument but 3 were given
CUDA available: True
tokenizer_config.json: 7.30kB [00:00, 2.49MB/s]
vocab.json: 2.78MB [00:00, 10.3MB/s]
merges.txt: 1.67MB [00:00, 7.31MB/s]
tokenizer.json: 7.03MB [00:00, 12.5MB/s]
Special tokens have been added in the vocabulary, make sure the associated word embeddings are fine-tuned or trained.
config.json: 100%|██████████████████████████████████████████████████████████████████████████████| 661/661 [00:00<00:00, 2.72MB/s]

CUDA available: True
tokenizer_config.json: 7.30kB [00:00, 2.49MB/s]
vocab.json: 2.78MB [00:00, 10.3MB/s]
merges.txt: 1.67MB [00:00, 7.31MB/s]
tokenizer.json: 7.03MB [00:00, 12.5MB/s]
Special tokens have been added in the vocabulary, make sure the associated word embeddings are fine-tuned or trained.
config.json: 100%|██████████████████████████████████████████████████████████████████████████████| 661/661 [00:00<00:00, 2.72MB/s]
model.safetensors.index.json: 35.6kB [00:00, 94.3MB/s]
model-000001-of-000002.safetensors: 100%|██████████████████████████████████████████████████████████████████████████████| 3.97G/3.97G [02:30<00:00, 26.4MB/s]
model-000002-of-000002.safetensors: 100%|██████████████████████████████████████████████████████████████████████████████| 2.20G/2.20G [01:19<00:00, 27.5MB/s]
Downloading shards: 100%|██████████████████████████████████████████████████████████████████████████████| 2/2 [03:53<00:00, 116.73s/it]
/usr/local/lib/python3.10/dist-packages/accelerate/utils/modeling.py:1384: UserWarning: Current model requires 587207040 bytes of buffer for offloaded layer s
, which seems does not fit any GPU's remaining memory. If you are experiencing a OOM later, please consider using offload_buffers=True.
    warnings.warn(
Loading checkpoint shards: 100%|██████████████████████████████████████████████████████████████████████████████| 2/2 [00:12<00:00, 6.27s/it]
generation_config.json: 100%|██████████████████████████████████████████████████████████████████████████████| 242/242 [00:00<00:00, 2.12MB/s]

WARNING:root:Some parameters are on the meta device device because they were offloaded to the cpu and disk.
```

Đoạn chat:

Bạn: Xin chào
 Trợ lý: Chào bạn! Tôi là trợ lý nhà hàng và tôi có thể giúp gì cho bạn?
 Bạn: Món phở bò giá bao nhiêu?
 Trợ lý: Món Phở Bò của chúng tôi có giá cơ bản là 55000 đồng.
 Bạn: Thời gian chuẩn bị của món phở bò là bao lâu?
 Trợ lý: Theo thông tin trên thực đơn, thời gian chuẩn bị của món Phở Bò là 25-35 phút.
 Bạn: Cơm Tấm Sườn Bì Chả có loại sườn nào?
 Trợ lý: Có, món Cơm Tấm Sườn Bì Chả của chúng tôi có thể được chọn với loại sườn non. Chi phí sẽ tăng lên 10,000 đồng.
 Bạn: Trà Sữa Trân Châu Đường Đen có topping gì thêm được?
 Trợ lý: Trà sữa trân châu đường đen có hai topping mà bạn có thể chọn:

1. Trân châu trắng
2. Pudding trứng

Bạn: Gà Rán Sốt Cay có kèm khoai tây chiên được không?
 Trợ lý: Xin lỗi, thông tin về món Gà Rán Sốt Cay trong thực đơn không mention thêm món ăn kèm như khoai tây chiên. Hãy kiểm tra lại hoặc liên hệ với nhân viên nhà hàng nếu cần thêm thông tin.
 Bạn: Phở Bò có tùy chọn thêm trứng không?
 Trợ lý: Phở Bò có tùy chọn thêm trứng. Giá thêm cho trứng tái là 5,000 đồng.
 Bạn: Món Ăn Sáng có những món nào?
 Trợ lý: Món Ăn Sáng có các món sau:

1. Bánh Mì Heo Quay - Giòn rụm với thịt heo quay, dưa leo, đồ chua và nước sốt đậm đà.
2. Bò Né - Thịt bò mềm, trứng ốp la, pate, xúc xích trên chảo gang nóng hổi, ăn kèm bánh mì.